

复旦大学研究生课程考试试卷

(2025 - 2026 学年第 2 学期)

授课学期： 春季

考试日期： 2026-7-1

课程名称： 神经网络的模型与应用

课程代码： MATH40054

开课院系： 数学科学学院

试卷类型： ☒A 卷 ☐B 卷

考试形式： ☐开卷 ☐闭卷 ☐课程论文 ☒其他

姓名： 张家诚 学号： 25210180106 成绩：

(共 7 题，每题 20 分，选 5 道题完成即可)

1. 对于如下过程描述的 LIF 模型

$$\frac{dV}{dt} = -g_L V + g_{syn} I_{syn}$$

$$\tau \frac{dI_{syn}}{dt} = -I_{syn} + \mu + \sigma \frac{dW}{dt}$$

这里 W 是一个标准的 Wiener 过程，膜电位达到阈值 V_{th} 产生动作电位放电，存在复位周期 τ_{ref} 。 I_{syn} 描述（一个）突触电流， τ 是其时间常数。 μ 、 σ 、 g_{syn} 、 τ 、 g_L 皆为常数。对此动作电位发放点稳态过程的 Inter-Spike-Interval 的随机变量记为 T ：

(1) 给出 T 的期望和方差的表达式，推导该神经元动作电位发放的更新函数(renewal function)的期望和方差表达式；

(2) 给定任意的期望 m 和方差 σ^2 ，如何构造参数 (g_{syn}, μ, σ) （给定

其他常数),使得 T 的期望和方差分别等于或者近似 m 和 σ^2 , 并通过数值模拟来验证你的结果。

2. 对于一个 ordinary renewal process $(X_1, X_2, \dots, X_n, \dots)$, 假设已知其更新间隔 X_n 各阶统计量, 请推导该神经元动作电位发放的更新函数(renewal function)的 n 阶统计量的表达式。

3. 考虑如下兴奋-抑制神经网络模型

$$\tau_E \frac{dv_E}{dt} = -v_E + [M_{EE}v_E - M_{EI}v_I + h_E]^+$$

$$\tau_I \frac{dv_I}{dt} = -v_I + [M_{IE}v_E - M_{II}v_I + h_I]^+$$

$[z]^+ = \max\{z, 0\}$, $v_{E,I}$ 分别表示兴奋性/抑制性神经元群的发放率, M_{ab} 分别是对应链接权重, $a, b=E, I$, $h_{E,I}$ 分别是兴奋性/抑制性神经元群接收到的外部刺激。分别给出该系统对应参数 τ_I 和 h_E 的 Hopf 分叉分析, 并给以实际数值模拟进行验证。

4. 多神经元对刺激方向的响应模型如下。假设每个神经元的条件发放率表示如下

$$f_a(s) = \exp\left(-\frac{(s - s_a)^2}{2\sigma_a^2}\right)$$

其中 $a=1, \dots, N$ 是神经元编号, s 是受到外部刺激的方向角度 ($[0, 180^\circ]$), s_a 是神经元 a 的偏好方向, $\sigma_a > 0$ 是神经元调谐函数的参数。假设

- 神经元动作电位发放之间是统计独立的；
- 神经元动作电位发放是一个泊松过程。

假设贝叶斯损失为平方差：

$$loss = (s - \hat{s})^2$$

$\hat{s}$ 是估计方向角度。

通过这 N 个神经元的动作电位发放时间点，建立对外部刺激方向 s 的最小方差的无偏 (MVUB) 估计，并计算其平方误差。可给出解析解，或者近似解，并进行数值模拟验证。

5. 分离附件中音频数据中的源信号并评估质量，并且比较至少两种算法。

6. 构建神经网络对 MNIST 数据集进行 0-9 手写数字的分类，并分别利用随机梯度下降 (SGD) 和自然梯度 (NG) 进行训练，并进行对比。

7. 利用 Reinforcement Learning 算法求解迷宫最短路径搜索问题。

迷宫图请见附件 (maze.jpg；黄色是出发位置)。

要求：任意给出中点位置，规划出最短路径或者告知不能到达。最好给出交互式的界面。

1 第 2 题:ordinary renewal process 的更新函数统计量

设普通更新过程的更新间隔为

$$X_1, X_2, \dots,$$

并假设它们独立同分布, 分布函数为 F . 记

$$S_k = X_1 + \dots + X_k, \quad S_0 = 0,$$

则时刻 t 前的更新次数为

$$N(t) = \max\{k : S_k \leq t\}.$$

这里 $N(t)$ 就是 renewal counting function. 因为

$$\{N(t) = k\} = \{S_k \leq t < S_{k+1}\},$$

所以它的分布可以写成

$$\mathbb{P}(N(t) = k) = F^{*k}(t) - F^{*(k+1)}(t), \quad k = 0, 1, 2, \dots, \quad (1)$$

其中 F^{*k} 表示 F 的 k 重卷积, 并约定 $F^{*0}(t) = 1$.

因此, $N(t)$ 的 n 阶原点矩为

$$\mathbb{E}[N(t)^n] = \sum_{k=0}^{\infty} k^n (F^{*k}(t) - F^{*(k+1)}(t)). \quad (2)$$

这个公式是最直接的精确表达式.

也可以用下降阶乘矩写得更紧凑. 记

$$(x)_r = x(x-1) \cdots (x-r+1),$$

则

$$\mathbb{E}[(N(t))_r] = r! \sum_{k=r}^{\infty} \binom{k-1}{r-1} F^{*k}(t), \quad r = 1, 2, \dots \quad (3)$$

这是因为当 $N(t) = m$ 时, 右端内部的组合数满足

$$\sum_{k=r}^m \binom{k-1}{r-1} = \binom{m}{r}.$$

再利用第二类 Stirling 数 $\left\{ \begin{smallmatrix} n \\ r \end{smallmatrix} \right\}$, 有

$$N(t)^n = \sum_{r=1}^n \left\{ \begin{smallmatrix} n \\ r \end{smallmatrix} \right\} (N(t))_r. \quad (4)$$

于是得到

$$\mathbb{E}[N(t)^n] = \sum_{r=1}^n \left\{ \begin{smallmatrix} n \\ r \end{smallmatrix} \right\} r! \sum_{k=r}^{\infty} \binom{k-1}{r-1} F^{*k}(t). \quad (5)$$

特别地, 更新函数的期望为

$$m(t) := \mathbb{E}[N(t)] = \sum_{k=1}^{\infty} F^{*k}(t). \quad (6)$$

二阶矩为

$$\mathbb{E}[N(t)^2] = \mathbb{E}[N(t)] + \mathbb{E}[N(t)(N(t) - 1)] = \sum_{k=1}^{\infty} F^{*k}(t) + 2 \sum_{k=2}^{\infty} (k-1)F^{*k}(t). \quad (7)$$

因此方差为

$$\text{Var}(N(t)) = \sum_{k=1}^{\infty} F^{*k}(t) + 2 \sum_{k=2}^{\infty} (k-1)F^{*k}(t) - \left(\sum_{k=1}^{\infty} F^{*k}(t) \right)^2. \quad (8)$$

2 第 3 题: 兴奋-抑制神经网络模型的 Hopf 分叉

考虑系统

$$\tau_E \frac{dv_E}{dt} = -v_E + [M_{EE}v_E - M_{EI}v_I + h_E]_+, \quad (9)$$

$$\tau_I \frac{dv_I}{dt} = -v_I + [M_{IE}v_E - M_{II}v_I + h_I]_+, \quad (10)$$

其中 $[z]_+ = \max\{z, 0\}$. 先在两个输入都为正的区域内分析, 即

$$M_{EE}v_E - M_{EI}v_I + h_E > 0, \quad M_{IE}v_E - M_{II}v_I + h_I > 0.$$

此时系统化为线性系统

$$\tau_E \dot{v}_E = (M_{EE} - 1)v_E - M_{EI}v_I + h_E, \quad (11)$$

$$\tau_I \dot{v}_I = M_{IE}v_E - (1 + M_{II})v_I + h_I. \quad (12)$$

其平衡点由

$$\begin{pmatrix} M_{EE} - 1 & -M_{EI} \\ M_{IE} & -(1 + M_{II}) \end{pmatrix} \begin{pmatrix} v_E^* \\ v_I^* \end{pmatrix} + \begin{pmatrix} h_E \\ h_I \end{pmatrix} = 0 \quad (13)$$

给出 Jacobian 矩阵为

$$J = \begin{pmatrix} \frac{M_{EE} - 1}{\tau_E} & -\frac{M_{EI}}{\tau_E} \\ \frac{M_{IE}}{\tau_I} & -\frac{1 + M_{II}}{\tau_I} \end{pmatrix}. \quad (14)$$

因此

$$\text{tr } J = \frac{M_{EE} - 1}{\tau_E} - \frac{1 + M_{II}}{\tau_I}, \quad (15)$$

$$\det J = \frac{M_{EI}M_{IE} - (M_{EE} - 1)(1 + M_{II})}{\tau_E \tau_I}. \quad (16)$$

以 τ_I 为分叉参数

Hopf 分叉要求

$$\text{tr } J = 0, \quad \det J > 0.$$

由 $\text{tr } J = 0$ 得到临界值

$$\tau_I^H = \frac{\tau_E(1 + M_{II})}{M_{EE} - 1} \quad (17)$$

其中需要 $M_{EE} > 1$. 同时还需要

$$M_{EI}M_{IE} > (M_{EE} - 1)(1 + M_{II}) \quad (18)$$

保证 $\det J > 0$. 横截性条件为

$$\frac{d}{d\tau_I} \operatorname{tr} J = \frac{1 + M_{II}}{\tau_I^2} \neq 0, \quad (19)$$

所以在上述条件下出现 Hopf 分叉.

取一组数值

$$\tau_E = 1, \quad M_{EE} = 2, \quad M_{EI} = 3, \quad M_{IE} = 3, \quad M_{II} = 1, \quad h_E = 2, \quad h_I = -1.$$

则

$$\tau_I^H = 2, \quad \omega_H = \sqrt{\det J|_{\tau_I=2}} = \sqrt{\frac{7}{2}} \approx 1.8708. \quad (20)$$

此时平衡点为

$$(v_E^*, v_I^*) = (1, 1),$$

并且两个阈值内部输入均为正, 所以该平衡点确实位于当前线性区域内.

数值模拟结果如下表. 可以看出, 当 $\tau_I < 2$ 时, 轨道收敛到平衡点; 当 $\tau_I > 2$ 时, 平衡点失稳, 并出现明显振荡.

τ_I	$\operatorname{tr} J$	$\det J$	后半段 v_E 范围	后半段 v_I 范围
1.0	-1.0000	7.0000	[1.0000, 1.0000]	[1.0000, 1.0000]
1.8	-0.1111	3.8889	[0.9983, 1.0016]	[0.9988, 1.0013]
2.0	0	3.5000	[0.3877, 1.5811]	[0.5891, 1.4109]
2.2	0.0909	3.1818	[0.2703, 1.7194]	[0.5398, 1.4985]
3.0	0.3333	2.3333	[0.0807, 2.1094]	[0.4898, 1.7204]

以 h_E 为分叉参数

在同一个激活区域内, Jacobian 矩阵 J 与 h_E 无关. 因此 h_E 只改变平衡点位置, 不改变局部线性化特征值. 也就是说, 在该阈值线性模型的固定激活区域内, h_E 不能引起经典 Hopf 分叉.

仍取上面的参数并固定 $h_I = -1$, 平衡点为

$$v_E^* = \frac{2h_E + 3}{7}, \quad v_I^* = \frac{3h_E + 1}{7}. \quad (21)$$

当 $h_E > -\frac{1}{3}$ 时, 平衡点位于正区域内. 只要不跨过阈值边界, 特征值不随 h_E 改变. 因此, h_E 的改变可能导致的是阈值边界上的非光滑变化, 而不是经典意义下的 Hopf 分叉.

3 第 4 题: 多神经元方向刺激的近似 MVUB 估计

假设在观测时间窗 $[0, T_0]$ 内, 第 a 个神经元对方向 s 的条件发放率为

$$f_a(s) = \exp\left(-\frac{(s - s_a)^2}{2\sigma_a^2}\right), \quad a = 1, \dots, N. \quad (22)$$

在题设假设下, 各神经元相互独立且发放为 Poisson 过程. 因此观测到的 spike time 在给定计数后不再额外携带关于 s 的信息, 核心统计量可以取为 spike count

$$n_a = N_a(T_0), \quad n_a | s \sim \operatorname{Pois}(T_0 f_a(s)).$$

于是似然函数为

$$L(s) = \prod_{a=1}^N \frac{(T_0 f_a(s))^{n_a}}{n_a!} \exp[-T_0 f_a(s)]. \quad (23)$$

对数似然为

$$\ell(s) = \sum_{a=1}^N n_a \log f_a(s) - T_0 \sum_{a=1}^N f_a(s) + C, \quad 0 \leq s \leq 180^\circ. \quad (24)$$

因此可以取近似 MVUB 估计为最大似然估计

$$\hat{s} = \arg \max_{0 \leq u \leq 180^\circ} \left\{ \sum_{a=1}^N n_a \log f_a(u) - T_0 \sum_{a=1}^N f_a(u) \right\}. \quad (25)$$

这里说“近似”是因为有限样本下一般很难写出严格的 MVUB 闭式解；但在 Poisson 独立模型下,MLE 是一致且渐近有效的,样本量较大时可达到 Cramer-Rao 下界,因此可作为近似 MVUB 解.

由于

$$f'_a(s) = f_a(s) \left(-\frac{s - s_a}{\sigma_a^2} \right), \quad (26)$$

Poisson 模型的 Fisher 信息为

$$I(s) = T_0 \sum_{a=1}^N \frac{(f'_a(s))^2}{f_a(s)} = T_0 \sum_{a=1}^N f_a(s) \frac{(s - s_a)^2}{\sigma_a^4}. \quad (27)$$

因此平方误差的理论近似为

$$\mathbb{E}[(\hat{s} - s)^2] \approx \frac{1}{I(s)} = \left[T_0 \sum_{a=1}^N f_a(s) \frac{(s - s_a)^2}{\sigma_a^4} \right]^{-1}. \quad (28)$$

数值验证中取

$$N = 36, \quad s_a = 0, 5, 10, \dots, 175, \quad \sigma_a = 20^\circ, \quad T_0 = 2, \quad s = 75^\circ.$$

计算得到

$$I(75^\circ) = 0.05009, \quad \frac{1}{I(75^\circ)} = 19.9646. \quad (29)$$

Monte Carlo 模拟 2000 次得到

$$\bar{\hat{s}} = 75.0514, \quad \text{Bias} = 0.0514, \quad \text{Var}(\hat{s}) = 20.5783, \quad \text{MSE} = 20.5707. \quad (30)$$

模拟 MSE 与 Cramer-Rao 下界非常接近,说明该估计在本例中是较好的近似最小方差无偏估计.

4 第 5 题: 音频盲源分离与质量评估

附件中给出了三个混合音频文件,记为

$$x_1(t), \quad x_2(t), \quad x_3(t).$$

把它们组成矩阵

$$X(t) = \begin{pmatrix} x_1(t) & x_2(t) & x_3(t) \end{pmatrix}.$$

盲源分离的基本模型为

$$X = AS, \quad (31)$$

其中 S 是未知源信号, A 是未知混合矩阵. 由于附件中没有给出干净源信号, 所以不能计算有监督的 SDR、SIR 等指标. 这里采用无监督评价指标: 重构误差、分离后信号之间的相关性、平方信号相关性以及峰度.

本文比较两种算法:

1. **PCA 白化法**: 只利用二阶统计量, 使输出信号两两不相关.
2. **FastICA**: 在白化基础上进一步最大化非高斯性, 从而尽量恢复统计独立的源信号.

设分离信号为 $\hat{S} = (\hat{s}_1, \hat{s}_2, \hat{s}_3)$. 评价指标取

$$E_{\text{rec}} = \frac{\|X - A\hat{S}\|_F}{\|X\|_F}, \quad (32)$$

$$C_1 = \text{mean}_{i < j} |\text{corr}(\hat{s}_i, \hat{s}_j)|, \quad (33)$$

$$C_2 = \text{mean}_{i < j} |\text{corr}(\hat{s}_i^2, \hat{s}_j^2)|. \quad (34)$$

其中 C_1 衡量普通线性相关性, C_2 用来粗略衡量非线性依赖. 若分离效果更好, 则 C_2 应更小.

程序运行结果如下.

算法	E_{rec}	C_1	C_2	平均绝对峰度
PCA	1.80×10^{-16}	1.19×10^{-16}	0.1273	0.3820
FastICA	2.40×10^{-16}	3.19×10^{-16}	0.0246	1.1303

两种方法的重构误差都接近机器精度, 这是因为都使用了三个分量进行重构. PCA 已经能做到线性去相关, 所以 C_1 很小. 但是 PCA 分离后的平方信号相关性 $C_2 = 0.1273$, 明显大于 FastICA 的 0.0246. 同时 FastICA 的平均绝对峰度更大, 说明其分离结果更加非高斯, 更符合独立源信号的特征. 因此, 本题中 FastICA 的盲源分离效果优于 PCA.

5 第 7 题: 用强化学习思想求解迷宫最短路径

把迷宫看成一个确定性 Markov decision process. 状态 s 是可通行像素点, 动作集合为

$$\mathcal{A} = \{\text{up}, \text{down}, \text{left}, \text{right}\}.$$

若动作撞墙, 则该动作不可取; 若动作可以走到相邻像素, 则奖励设为

$$r(s, a) = -1.$$

终点状态 g 的价值为 $V(g) = 0$. 在折扣因子 $\gamma = 1$ 的 episodic 情形下, Bellman 最优方程为

$$V(s) = \max_{a \in \mathcal{A}(s)} \{-1 + V(s')\}, \quad (35)$$

其中 s' 是从 s 采取动作 a 后到达的状态. 由于每走一步的奖励都是 -1 , 最大化累计奖励等价于最小化路径长度. 因此, 收敛后的贪心策略给出的就是最短路径.

在实现中, 先对 maze.jpg 做预处理: 白色区域视作墙, 黑色区域视作可通行区域, 并对墙体做轻微膨胀来消除图像中斜线纹理造成的小孔. 黄色点自动识别为出发点. 程序检测到出发点像素坐标为

$$S = (558, 402).$$

这里坐标采用图像坐标, 即 (x, y) . 任选一个终点

$$G = (320, 249).$$

程序给出的最短路径长度为

$$\boxed{6115 \text{ pixel steps}}. \quad (36)$$

红色曲线为最短路径, 黄色点为出发点, 绿色点为终点.




图 1: 迷宫最短路径结果示意图

代码仓库

本题所用 Python 代码以及运行结果已上传至 GitHub 仓库:

[neural-network-models-and-applications](#)